WYKRYWANIE PASÓW NA JEZDNI Z WYKORZYSTANIEM BIBLIOTEKI OPENCV

Jakub Tomaszewski

Spis treści

1. Opis i cel projektu

Założeniem projektu było stworzenie programu wykrywającego pasy na jezdni, który zostanie wykorzystany w pojeździe autonomicznym. Projekt został przygotowany w taki sposób, aby jego działanie było możliwe zarówno na systemie Windows jak i Linux.

2. Wybór języka

Python jest obecnie najpopularniejszym oraz stale rozwijanym językiem programowania. Istnieją setki modułów rozszerzających jego funkcjonalność i ułatwiających implementację zaawansowanych projektów. Powyższe powody zdecydowały o wykorzystaniu tego języka w wersji python=3.6.9

3. Wykorzystane pakiety

- numpy==1.18.1
- opencv-python==4.3.0.36

4. Pomysł

Pomysł na sam algorytm został zaczerpnięty od Pana Ross'a Kippenbrock'a, który podczas PyData 2017 w Berlinie zaprezentował jego działanie.
https://www.youtube.com/watch?v=VyLihutdsPk

5. Podział i opis poszczególnych modułów programu

Program został podzielony na 5 modułów:

- `lane_filter.py` – moduł zawierający 2 klasy. *LaneFIlter* – zawiera funkcje służące do przetwarzania obrazu. *Line* – reprezentuje linie na drodze oraz zawiera funkcje służące do przewidywania ich przebiegu.
- `trackbar.py` – moduł zawierający trackbary to wygodniejszego dostosowania interesującego nas regionu
- `warper.py` – moduł zawierający klasę służącą do tworzenia warp perspective (widok z lotu ptaka)
- `script.py` – moduł zawierający algorytm wykrywający linie
- `detect_lines.py` – moduł główny (tzw. moduł main), łączy cały program w całość i kontroluje jego działanie.

6. Ogólny opis rozwiązania

Rozwiązanie problemu zostało podzielone na poszczególne etapy:

- **Perspective warp** – (moduł `warper.py`) czyli utworzenie rzutu obrazu „z góry", potocznie nazywane także widokiem z lotu ptaka (birds eye view). Ułatwi to późniejsze obliczenia oraz wykrywanie linii.

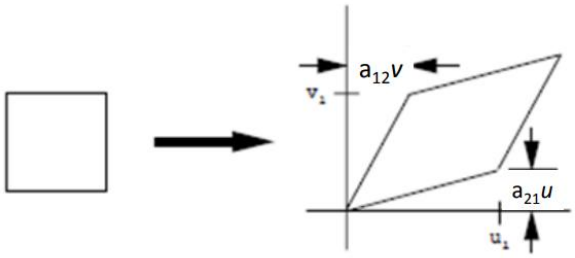

http://docdingle.com/teaching/cs545/presents/p12b_cs545_WarpsP2.pdf

Utworzona funkcja:

```
def warp_matrix(self, image):
    """Creates a warp perspective of an image (birds eye view)

    Parameters
    ----------
    image -- numpy array representing an image

    Returns
    -------
    Warped image
    """

    perspective = cv2.getPerspectiveTransform(self.source_pts, self.dest_pts)
    shape = image.shape[1], image.shape[0]

    return cv2.warpPerspective(image, perspective, shape, flags=cv2.INTER_NEAREST)
```

W celu ułatwienia wyboru najbardziej odpowiednich punktów, utworzony został trackbar ustalający współrzędne interesujących nas punktów (moduł `trackbar.py`).

- **Przetwarzanie obrazu** – (moduł `lane_filter.py`) jest to najważniejszy krok przy rozwiązywaniu jakiegokolwiek problemu z zakresu Computer Vision. Istnieje wiele technik tzw. image preprocessingu i ich dobór zależy konkretnie od rozwiązywanego problemu. W omawianym projekcie wykorzystane zostały takie metody jak:

    a. Gaussian blur – polega na usuwaniu szumu z obrazu poprzez użycie specjalnego filtra w tym przypadku o wymiarze 3x3. Samo działanie metody zostało świetnie wytłumaczone w filmie widniejącym na kanale **Computerphile** https://www.youtube.com/watch?v=C_zFhWdM4ic

    Utworzona funkcja:

```python
def gaussian_blur(image):
    """Applies gaussian blur to an image

    Parameters
    ----------
    image -- numpy array representing an image

    Returns
    -------
    Image with gaussian blur appied
    """

    # Reducing noise - smoothing
    blurred_img = cv2.GaussianBlur(image, (3, 3), 0)

    return blurred_img
```

    b. **Image thresholding** – technika polegająca na pozostawieniu jedynie pikseli o wartościach większych od podanego progu (threshold)

Utworzona funkcja:

```python
def img_threshold(image, threshold, channel_number):
    """Applies a threshold to a specific image color channel

    Parameters
    ----------
    image -- numpy array representing an image

    threshold -- an integer value to threshold the image

    channel_number -- color channel index to be thresholded

    Returns
    -------
    Binary image after thresholding
    """

    if channel_number not in range(image.shape[2]):
        raise IncorrectImage('Insufficient color channels')

    # Setting the channel
    channel = image[:, :, channel_number]

    return cv2.threshold(channel, threshold, 255, cv2.THRESH_BINARY)
```

W tym przypadku także został utworzony trackbar w celu wyznaczenia najbardziej optymalnych wartości dla progu (threshold)

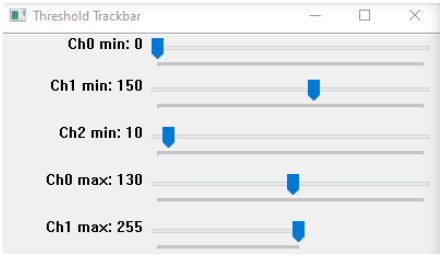

- **Konwersja do innej skali kolorów.** Standardowo obrazy reprezentowane są w skali RGB (red, green, blue). W każdym color channel znajdują się wartości od 0 do 255. Częstym zabiegiem podczas image preprocessing jest konwersja do innej skali kolorów w celu wyróżnienia różnych części obrazu (np. brzegów). Wybór danego color channelu zależy od rozwiązywanego od nas problemu. Jest to zazwyczaj żmudy proces polegający na wielokrotnym sprawdzaniu różnych skali kolorów. W tym konkretnym przypadku najlepiej sprawdziła się skala kolorów o nazwie HSL (Hue, Saturation, Light)

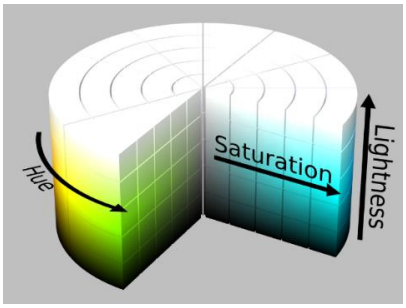

https://en.wikipedia.org/wiki/HSL_and_HSV#/media/File:HSL_color_solid_cylinder_saturation_gray.png

Utworzona funkcja:

```python
def convert_to_hsl(image):
    """Converts given image to HSL color scale

    Parameters
    ----------
    image -- numpy array representing an image

    Returns
    -------
    Image in HSL color scale
    """

    if not isinstance(image, np.ndarray):
        raise IncorrectImage('Incorrect image type, numpy array required')
    else:
        return cv2.cvtColor(image, cv2.COLOR_BGR2HLS)
```

a. **Sobel operator** – jest to także używanie specjalnego filtra, jednak w tym przypadku w celu wykrycia pionowych linii na zdjęciu. Podobnie jak w przypadku usuwanie szumu ze zdjęcia (podpunkt a.) działanie omawianej metody zostało świetnie wytłumaczone w filmie widniejącym na kanale **Computerphile** https://www.youtube.com/watch?v=uihBwtPIBxM

```python
def apply_sobel(image, channel_number, magnitude_thresh=(50, 210)):
    """Applies sobel operator

    Parameters
    ----------
    image -- numpy array representing an image

    channel_number -- number of the channel to extract

    magnitude_thresh -- threshold for image filtering
        default = (50, 210)

    Returns
    -------
    Binary image of applied sobel
    """

    # Setting the channel number
    channel = image[:, :, channel_number]

    # Searching for vertical lines
    sobel_x = cv2.Sobel(channel, cv2.CV_64F, 1, 0)

    scaled_sobel_x = np.uint8(255 * sobel_x/np.max(sobel_x))

    binary = np.zeros_like(scaled_sobel_x)
    binary[(scaled_sobel_x >= magnitude_thresh[0]) & (scaled_sobel_x <= magnitude_thresh[1])] = 255

    return binary
```

Rezultat po dokonaniu przetwarzania obrazu

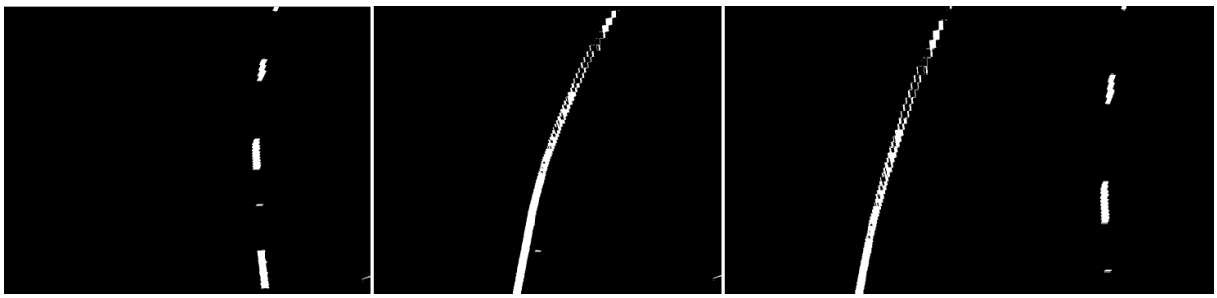

7. Algorytm (moduł `script.py`).

Wykorzystany algorytm nie jest bardzo skomplikowany i nie wymaga wielkiej mocy obliczeniowej. Można go podzielić na dwie metody, które działając wspólnie usprawniają wykrywanie linii na drodze.

- Metoda I
  Polega ona na zsumowaniu dolnej połowy obrazu w celu znalezienia miejsc, w których zaczynają się linie na jezdni. Po wcześniejszym przetworzeniu obrazu otrzymaliśmy tzw. binary image, czyli obraz z jednym color channelem. Znajdują się w nim tylko piksele o dwóch wartościach – białej (255) i czarnej (0). Po zsumowaniu obrazu wzdłuż osi Y, największe wartości będą reprezentowały duże skupiska białych pikseli, tzn. linii na jezdni.

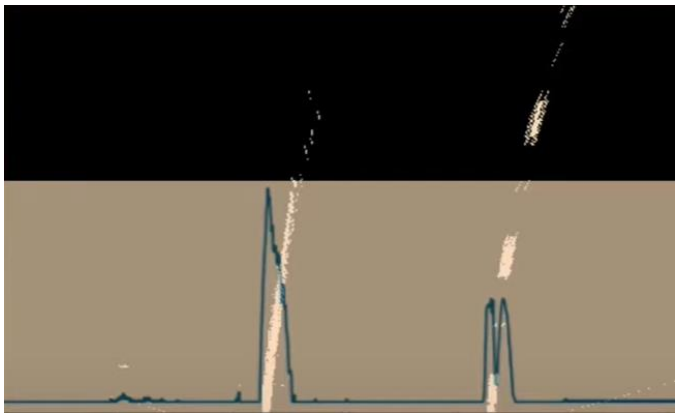

https://www.youtube.com/watch?v=VyLihutdsPk

Następnie w miejscach, w których po zsumowaniu występowały największe wartości „rysowany" zostaje prostokąt (w omawianym przypadku o szerokości 260 i wysokości 72 pikseli). Utworzona zostaje także lista, w której zostają umieszczone koordynaty wszystkich niezerowych pikseli (białych) znajdujących się w zaznaczonym obszarze.

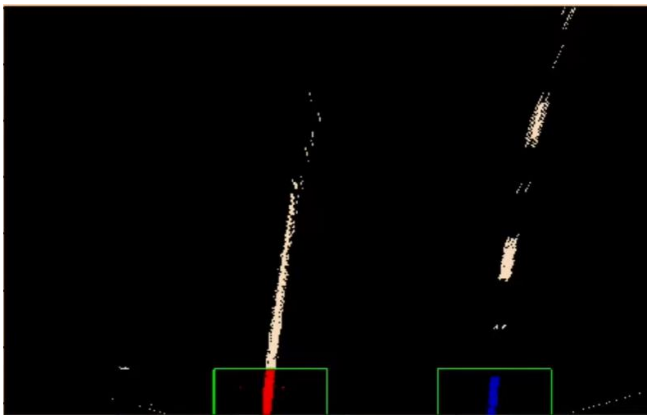

https://www.youtube.com/watch?v=VyLihutdsPk

Po zebraniu wszystkich współrzędnych w liście, obliczone zostają średnie ze współrzędnych X oraz Y, które będą wyznaczać środek następnego prostokąta.

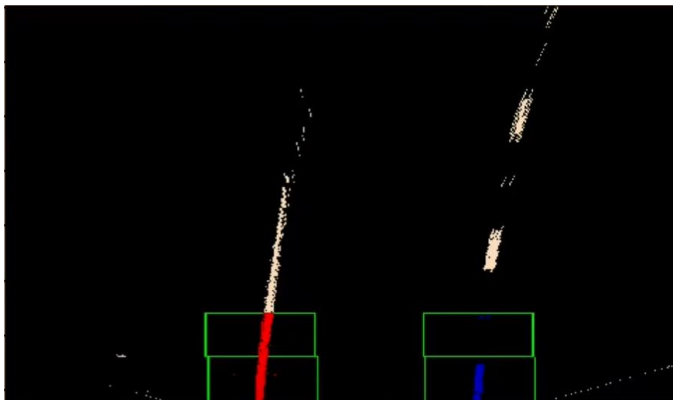

https://www.youtube.com/watch?v=VyLihutdsPk

Ta czynność zostaje powtórzona, dopóki prostokąty nie dotrą do górnej granicy obrazu.

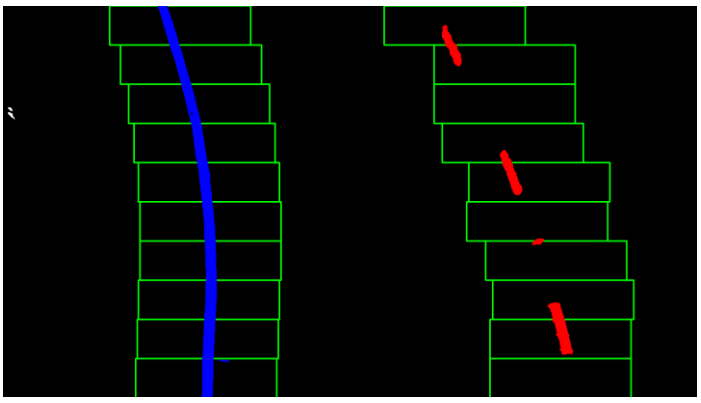

Po „narysowaniu" wszystkich prostokątów użyta zostaje funkcja **polyfit** z pakietu numpy, która wyznacza najlepiej dopasowaną linię do konkretnych współrzędnych punktów.

```
left_fit = np.polyfit(lefty, leftx, 2)
right_fit = np.polyfit(righty, rightx, 2)
```

Po dopasowaniu linii

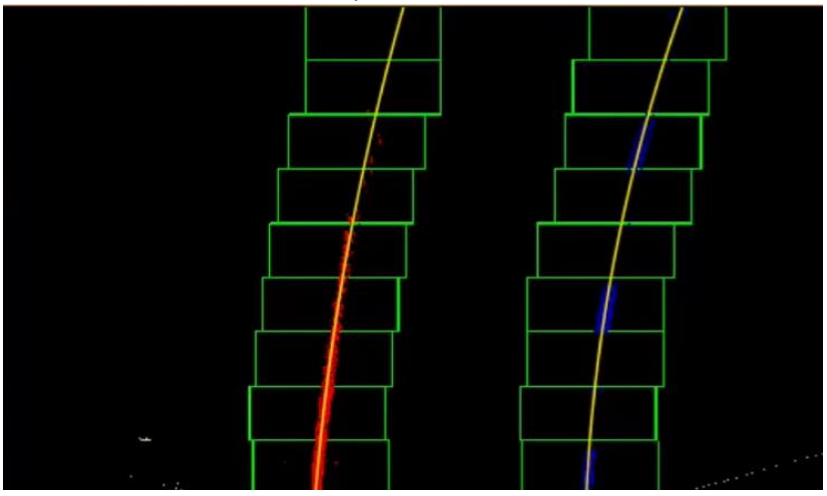

https://www.youtube.com/watch?v=VyLihutdsPk

- Metoda II

  W tym przypadku zamiast tworzyć wiele prostokątów, program korzysta z poprzednio dopasowanej linii, wzdłuż której tworzony zostaje margines o szerokości 200 pikseli (100 w lewo i 100 w prawo). Tak jak poprzednio, wszystkie współrzędne punktów leżące w zaznaczonym obszarze zostają umieszczone w liście, a następnie funkcja **polyfit** wyznacza najlepiej dopasowaną linię.

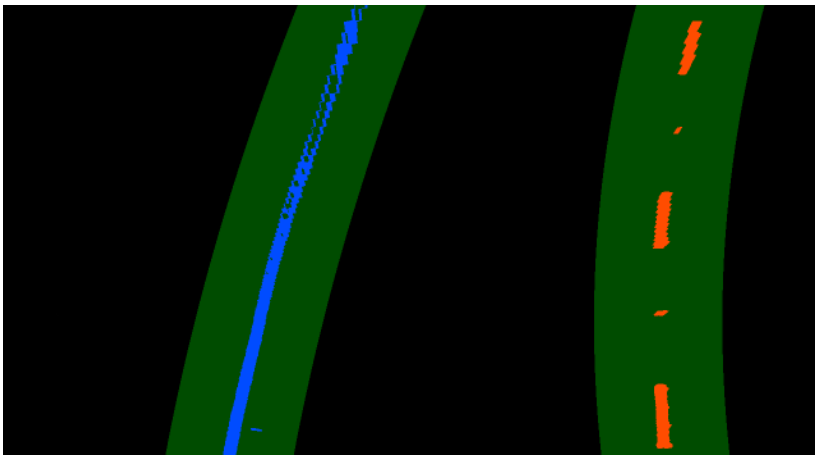

W celu obliczenia promienia krzywizny skrętu zastosowano poniższe kalkulacje:

```
                Polyfit equation: y = Ax² + Bx + C
                fit = [A, B, C]

curve_rad = ((1 + (2*fit[0]*y_eval + fit[1])**2)**1.5) /
np.absolute(2*fit[0])
```

https://www.youtube.com/watch?v=VyLihutdsPk

Ostatnim etapem działania algorytmu jest powrót do oryginalnego obrazu za pomocą funkcji `inverse_warp_matrix` z modułu `warper.py` oraz wizualizacja toru jazdy samochodu.

8. Rezultaty

W celu obliczenia odległości samochodu od środka jego toru jazdy przyjęto założenie, że kamera znajduje się idealnie w połowie szerokości samochodu. Przyjęto także założenie, że w USA szerokość jezdni wynosi 3.7 m. Wielokrotne testy wykazały, że program odpowiednio wykrywa linie w różnych warunkach, jednak jego parametry należy dostroić konkretnie do danej kamery.

9. Bibliografia

- https://opencv.org/
- https://www.youtube.com/watch?v=VyLihutdsPk